Reporte de Modelos – Proyecto Integrador FinanceGuard

Cierre del proyecto: reducción de churn en banca digital. Documento de conclusiones basado en los Avances 1, 2 y 3. Todas las cifras provienen de los notebooks ejecutados; las métricas de evaluación corresponden al conjunto de test (2.000 clientes, 407 abandonos) salvo indicación.

1. Resumen ejecutivo

FinanceGuard enfrenta una **tasa de churn del 20,4 %** (2.037 de 10.000 clientes). A lo largo de tres avances se construyó un modelo baseline (regresión logística), se compararon modelos de Gradient Boosting y Stacking con optimización de hiperparámetros, y se exploró la estructura de la cartera con aprendizaje no supervisado.

Hallazgos principales:

- **Los ensambles superan claramente al baseline.** El ROC-AUC en test pasa de 0,775 (regresión logística) a 0,865–0,870 (+9,0 a +9,5 puntos), el PR-AUC de 0,479 a 0,707–0,727 y el F1 con umbral 0,5 de 0,284 a 0,56–0,61.
- **No hay un único mejor algoritmo.** XGBoost, LightGBM, CatBoost y el Stacking son equivalentes: sus diferencias son de milésimas en ROC-AUC y menores que la variabilidad entre folds (≈0,01). Se recomienda **XGBoost optimizado con GridSearchCV** por ser un único modelo liviano que rinde como el Stacking.
- **El umbral de decisión pesa más que el algoritmo.** Con el umbral 0,5 todos los modelos pierden dinero con la métrica de negocio (+100 por acierto, −150 por positivo no detectado, −20 por falsa alarma). Con el umbral óptimo (0,08, elegido en validación cruzada) el XGBoost optimizado pasa de −6,23 a **+8,99 dólares por cliente** en test, frente a 4,42 de marcar a todos los clientes.
- **Segmentación débil.** K-Means con K=2 separa a los clientes **con saldo** de los **mayormente sin saldo** (churn 22,4 % frente a 17,5 %). La silueta es baja (0,15), por lo que los segmentos son tendencias y no grupos nítidos.
- **Variables clave:** `NumOfProducts`, `IsActiveMember`, `Age` y `Geography_Germany` concentran la mayor importancia en el modelo final y coinciden con lo observado en la regresión logística y en los perfiles de cluster.

---

2. Síntesis por avance

2.1 Avance 1 – Regresión logística (baseline)

Objetivo: establecer un modelo baseline interpretable para predecir churn.

- Dataset: 10.000 clientes, 14 columnas originales, sin valores nulos, 20,37 % de abandono (desbalance 80/20). Partición estratificada 80/20 (8.000 para entrenamiento y 2.000 para test).
- Variables del modelo (11): `CreditScore`, `Age`, `Tenure`, `Balance`, `NumOfProducts`, `HasCrCard`, `IsActiveMember`, `EstimatedSalary`, `Geography_Germany`, `Geography_Spain` y `Gender_Male` (one-hot con `drop_first`; referencias: Francia y mujer). Las numéricas se estandarizaron.

- Multicolinealidad: VIF máximo de 1,34, sin problemas relevantes.

Desempeño en test

Métrica	Umbral 0,5	Con pesos de clase balanceados
Accuracy	0,808	0,71
Precision (abandono)	0,59	0,39
Recall (abandono)	0,19	0,70
F1 (abandono)	0,28	0,50
ROC-AUC	0,775	0,777

El modelo acierta casi todos los clientes que se quedan (recall 0,97) pero detecta solo 1 de cada 5 abandonos. Balancear los pesos de las clases sube el recall a 0,70 a costa de la precisión, lo que ya anticipa que el punto de corte es una decisión de negocio.

Interpretación de los odds ratios (variables continuas por cada +1 desvío estándar)

Variable	Odds ratio (IC 95 %)	Lectura
`Geography_Germany`	2,28 (1,97–2,65)	Mayor riesgo que Francia
`Age`	2,10 (1,98–2,22)	A mayor edad, mayor riesgo (≈ el doble por cada ~10 años)
`Balance`	1,17 (1,09–1,26)	Mayor riesgo con saldos altos
`IsActiveMember`	0,36 (0,31–0,40)	Factor protector
`Gender_Male`	0,59 (0,53–0,67)	Menor riesgo que las mujeres
`CreditScore`	0,92 (0,87–0,97)	Efecto pequeño

`Tenure`, `EstimatedSalary`, `HasCrCard` y `Geography_Spain` no son estadísticamente significativas. `NumOfProducts` (OR 0,93) no es lineal: abandonan el 27,7 % de quienes tienen 1 producto, el 7,6 % con 2, el 82,7 % con 3 y el 100 % con 4 (60 clientes), patrón que un coeficiente lineal no refleja.

Fortalezas: fácil de explicar al negocio, rápido de entrenar y punto de referencia para los modelos siguientes.

Limitaciones: supone relaciones lineales en el log-odds, no captura patrones no lineales como el de `NumOfProducts` y, con el umbral 0,5, deja escapar a 4 de cada 5 abandonos.

2.2 Avance 2 – Gradient Boosting y optimización

Objetivo: mejorar la predicción con modelos de ensamble, optimizar hiperparámetros y evaluar el impacto económico del umbral de decisión.

Comparación de modelos (validación cruzada estratificada de 5 folds)

Modelo	ROC-AUC CV (± desvío)	Tiempo de entrenamiento (5 folds, 1 hilo)
Regresión logística (baseline)	0,763 (± 0,020)	1,6 s
Random Forest	0,859 (± 0,009)	53,4 s
XGBoost	0,861 (± 0,013)	12,5 s
LightGBM	0,860 (± 0,012)	5,2 s
CatBoost	0,868 (± 0,012)	22,0 s
Stacking (XGBoost + LightGBM + CatBoost, meta-modelo logístico)	0,867 (± 0,012)	254,6 s

Las diferencias entre los ensambles son menores que el desvío entre folds. El Stacking tarda unas 20 veces más que XGBoost sin una mejora distinguible, por lo que se descartó. Se seleccionó **XGBoost** entre las alternativas equivalentes para la etapa de optimización.

Optimización de hiperparámetros de XGBoost

- **GridSearchCV** (8 combinaciones, 40 ajustes): `max_depth` 3, `learning_rate` 0,05 y `n_estimators` 300. ROC-AUC en CV de 0,8609 a 0,8646 y en test de 0,8645 a **0,8685**.
- **RandomizedSearchCV** (12 combinaciones, 60 ajustes): `max_depth` 3, `learning_rate` ≈ 0,098, 157 árboles, `subsample` ≈ 0,76 y `colsample_bytree` ≈ 0,81. ROC-AUC en CV de 0,8666 y en test de 0,8701.
- Ambas estrategias son equivalentes y la mejora sobre XGBoost sin ajustar es leve (+0,004), menor que el desvío entre folds. Se adoptó **GridSearchCV** por explorar de forma exhaustiva la grilla definida y requerir menos ajustes. La búsqueda se hizo sobre ROC-AUC, que no depende del umbral.

Resultados en test

Modelo	ROC-AUC	PR-AUC	F1 (umbral 0,5)	Recall	Precision
Regresión logística	0,775	0,479	0,284	0,187	0,589
Random Forest	0,865	0,707	0,564	0,428	0,829
XGBoost	0,865	0,712	0,602	0,494	0,770
LightGBM	0,865	0,709	0,591	0,474	0,785
CatBoost	0,870	0,727	0,615	0,494	0,814
Stacking	0,870	0,726	0,614	0,496	0,805
XGBoost (GridSearch)	0,869	0,717	0,599	0,489	0,774

Modelo	ROC-AUC	PR-AUC	F1 (umbral 0,5)	Recall	Precision
XGBoost (RandomizedSearch)	0,870	0,720	0,600	0,479	0,803

Importancia de variables (gain, XGBoost optimizado): `NumOfProducts` (≈0,22), `IsActiveMember` (≈0,21), `Age` (≈0,20) y `Geography_Germany` (≈0,14) concentran la mayor parte; siguen `Gender_Male` y `Balance` (≈0,06 cada una) y el resto queda por debajo de 0,03. La importancia describe qué usa el modelo, no causalidad ni el sentido del efecto.

Umbral de decisión óptimo (XGBoost con GridSearch)

El umbral se eligió con predicciones fuera de fold sobre entrenamiento (óptimo 0,08; meseta de 0,06 a 0,09; umbral teórico 0,074) y se aplicó una sola vez sobre test.

Test	Umbral 0,50	Umbral óptimo 0,08
Clientes marcados	12,9 %	59,6 %
Precision	0,774	0,320
Recall	0,489	0,936
Positivos detectados / que se escapan	199 / 208	381 / 26
Falsas alarmas	58	811
Beneficio total	−12.460	+17.980
Beneficio por cliente	**−6,23**	**+8,99**

Referencias por cliente en test: marcar a todos = 4,42; no predecir nada = −30,52. Con el umbral óptimo, los ensambles alcanzan entre 8,2 y 8,8 dólares por cliente en validación cruzada (desvío entre folds de 0,3 a 0,7), mientras que la regresión logística llega a 5,8, apenas 1,4 por encima de marcar a todos. La elección del modelo no cambia con el umbral óptimo.

2.3 Avance 3 – Aprendizaje no supervisado

Objetivo: segmentar clientes sin usar la etiqueta de churn y cruzar después los segmentos con el abandono.

K-Means (K=2)

- Se evaluó K de 2 a 8. La silueta alcanza su máximo en K=2 (0,153; con K=3 baja a 0,122). El método del codo no muestra un quiebre claro y el índice de Davies-Bouldin mejora al aumentar K, por lo que la decisión se apoya en la silueta y en la simplicidad. Una silueta de 0,15 es baja: la cartera no tiene grupos naturales nítidos.

	Cluster 0: con saldo	Cluster 1: mayormente sin saldo
Clientes	5.908 (59,1 %)	4.092 (40,9 %)

	Cluster 0: con saldo	Cluster 1: mayormente sin saldo
Saldo medio	≈ USD 122.518 (ninguno con saldo cero)	≈ USD 10.025 (88,4 % con saldo cero)
Productos promedio	1,30	1,86
Alemania / Francia / España	39,4 % / 40,8 % / 19,8 %	4,5 % / 63,6 % / 31,9 %
Edad media	39,1	38,7
Miembros activos	51,6 %	51,4 %
Tasa de churn	**22,4 %**	**17,5 %**

La diferencia de 4,9 puntos es estadísticamente significativa (chi-cuadrado 35,5; $p \approx 2{,}5 \times 10^{-9}$) pero moderada: ningún segmento es de riesgo extremo.

PCA y t-SNE: las dos primeras componentes explican el 33,1 % de la varianza (hacen falta 6 para superar el 85 %). PC1 contrapone `Balance` frente a `NumOfProducts` y es el eje en el que se separan los dos clusters; PC2 combina `EstimatedSalary`, `Tenure` y `Age`, donde los grupos se solapan.

DBSCAN (`eps` 2,2 y `min_samples` 22): encuentra un único grupo denso y **37 clientes atípicos (0,4 %)**; 31 de ellos tienen 4 productos, tienen en promedio 49,9 años y el 94,6 % abandonó. Es un detector de perfiles anómalos más que un segmentador, y su resultado es sensible a `eps`.

Variables derivadas: `cluster_kmeans`, `cluster_dbscan` y `cluster_churn_rate`. Esta última usa la etiqueta, por lo que en un flujo supervisado solo debería calcularse con los datos de entrenamiento.

Lecciones del no supervisado

- La segmentación no reemplaza al modelo de churn: lo complementa con una descripción de la cartera. Los segmentos se explican por `Balance`, `NumOfProducts` y `Geography`, las mismas variables que ya dominaban los modelos supervisados.
- Los clusters son débiles (silueta 0,15) y deben leerse como tendencias.

---

3. Lecciones aprendidas

3.1 Supervisado frente a no supervisado

Criterio	Supervisado (regresión logística, XGBoost, Stacking)	No supervisado (K-Means, PCA, DBSCAN)
Objetivo	Predecir quién abandona y con qué probabilidad	Entender perfiles de la cartera
Uso de la etiqueta	Sí (`Exited`)	No (solo para el análisis posterior)
Salida principal	Probabilidad de churn por cliente	Segmentos y perfiles promedio

Criterio	Supervisado (regresión logística, XGBoost, Stacking)	No supervisado (K-Means, PCA, DBSCAN)
Acción típica	Lista priorizada de clientes a contactar	Diseño de mensajes y revisión de perfiles atípicos
Interpretabilidad	Odds ratios o importancia de variables	Centroides y tasas por cluster

Recomendación: usar el modelo supervisado para el scoring y la priorización, y el análisis no supervisado como apoyo descriptivo, no como sustituto.

3.2 Consideraciones para futuros proyectos de churn

- **El umbral es una decisión de negocio.** Con costos como los del proyecto, el umbral óptimo (≈ 0,07–0,08) está muy por debajo de 0,5. Un valor orientativo es costo de falsa alarma / (costo de falsa alarma + ganancia por acierto + pérdida por positivo no detectado). Debe elegirse con validación cruzada, nunca con el test.
- **Siempre comparar contra la regla trivial.** Un beneficio positivo solo es valor si supera a marcar a todos los clientes (4,42 por cliente).
- **Cuidado con el desbalance.** La accuracy engaña (un modelo que dijera que nadie se va acertaría el 80 %); usar ROC-AUC, PR-AUC, recall, F1 y la métrica de negocio.
- **Comparar con justicia.** Fijar un hilo por modelo para medir tiempos, usar los mismos folds y evitar elegir modelos mirando el test.
- **La relación con el churn no siempre es lineal.** `NumOfProducts` muestra que conviene complementar la regresión logística con modelos de árboles.
- **Optimizar hiperparámetros rinde poco cuando los datos fijan el techo:** la mejora fue de +0,004 en ROC-AUC. Conviene invertir antes en nuevas variables.

---

4. Recomendaciones estratégicas

1. **Desplegar XGBoost (GridSearchCV) como modelo único** para scoring periódico, con lista priorizada por probabilidad de churn. Rinde como el Stacking con mucho menos costo de entrenamiento y mantenimiento.
2. **Operar con el umbral óptimo (≈ 0,08) y no con 0,5.** Con los costos asumidos, en test se detecta el 94 % de los abandonos y el beneficio por cliente pasa de −6,23 a +8,99. Recalcular el umbral si cambian los costos reales.
3. **Verificar la capacidad operativa.** Con el umbral óptimo se marca al 60 % de los clientes y solo 3 de cada 10 alertas son abandonos reales. Si contactar a un cliente cuesta bastante más de 20 dólares o no se puede atender ese volumen, el umbral debe subir.
4. **Priorizar a los grupos de mayor riesgo observado:** Alemania (churn 32,4 % frente a 16,2 % en Francia y 16,7 % en España), clientes de 40 a 60 años (34 % y 56 %), clientes no activos (26,9 % frente a 14,3 % de los activos) y clientes con 3 o 4 productos (82,7 % y 100 %, aunque son solo 326 clientes). Conviene investigar de forma cualitativa las causas, en especial en el último caso.

5. **Fomentar el engagement y la contratación de 2 productos**, los grupos con menor abandono (7,6 % con 2 productos).
6. **Monitoreo:** seguir ROC-AUC, PR-AUC, recall, la proporción de clientes marcados y la distribución de las probabilidades; reentrenar y recalibrar el umbral periódicamente con los resultados de las campañas.
7. **Medir el impacto real con una prueba controlada** (grupo contactado y grupo de control) antes de escalar las campañas, porque los resultados dependen de costos asumidos.

---

5. Limitaciones

- **Costos asumidos:** los +100, −150 y −20 son supuestos; los montos en dólares deben leerse como ilustrativos y la conclusión robusta es cualitativa (el umbral óptimo es mucho menor que 0,5).
- **Dataset estático, sin fecha:** no es posible validar en el tiempo ni detectar *drift*, y la evaluación se hizo sobre una única partición de test (que se usó como confirmación final).
- **Variables sensibles:** `Geography` y `Gender` son entradas de todos los modelos. Si las predicciones se usan para tratar de forma distinta a los clientes, conviene revisar el desempeño por grupo y evitar un trato diferencial por nacionalidad o género.
- **Correlación no es causalidad:** los odds ratios, la importancia de variables y los perfiles de cluster describen asociaciones.
- **Segmentación débil:** la silueta de 0,15 indica clusters con mucho solapamiento.

---

6. Referencia a materiales del proyecto

- **Avance 1:** `1_EDA_RegresionLogistica.ipynb`
- **Avance 2:** `2_GradientBoosting_Optimizacion.ipynb`
- **Avance 3:** `3_AprendizajeNoSupervisado.ipynb`
- **Datos:** `Churn_Modelling.csv` (10.000 clientes, 14 columnas) y `Churn_Modelling_limpio.csv` (versión codificada usada en los avances 2 y 3)